

基于深度学习的 T1 脑 MRI 图像去噪

计算神经学期末作业报告

盖烈森

23307130013@m.fudan.edu.cn

摘要

本报告针对 UK Biobank T1 脑 MRI 配对去噪任务，采用“三层递进评估 + 一层全量验证”的实验框架，在严格变量控制下遴选最优训练配置。全文所有定量指标均仅在脑组织掩膜（强度 > 0 ）内计算，训练损失 L1 项同步按该 tissue-only 口径计算以保持优化 - 评价对齐。Stage A 损失消融确定纯 L1（验证集增益 2.32 dB）显著优于 L1+SSIM 组合（1.21 dB）；Stage B 同条件对比五类架构，前四名极差仅 0.06 dB 进入 Tier-1；Stage C 跨种子中期验证中 UNet++ Lite 和 U-Net 32ch 表现稳定（ $2\sigma = 0.17, 0.19$ dB），SE-UNet 出现 1 例训练失效（ $2\sigma = 1.77$ dB），U-Net 64ch 波动居中（ $2\sigma = 0.82$ dB）；Stage D 全量训练中 SE-UNet 以 test PSNR 48.23 dB（增益 2.77 dB）取得数值最优，但跨种子稳定性风险限制其普适性；U-Net 32ch 以 48.14 dB（增益 2.68 dB）和优异可复现性当选推荐方案，较 NLM 基线（0.81 dB）提升 3.3 倍；U-Net 64ch 以 4 倍参数量仅换得微弱增益（2.72 dB），参数效率低；UNet++ Lite 因容量 - 数据错配发生泛化坍塌——验证增益从 step 250 的 2.29 dB 崩溃至训练终点 0.3–0.5 dB。信号分箱与 ME 追踪揭示 Rician 噪声的信号依赖性：增益从低信号区 6.72 dB 递减至高信号区 1.58 dB，去噪后 ME 全局收束至 -3.1×10^{-4} ，证实通用 L1 残差学习已能有效压制 Rician 正偏差。

1 引言

1.1 研究背景

磁共振成像（MRI）幅度图像上的噪声服从 Rician 分布——低信号区域的噪声方差远大于高信号区域，对灰白质边界等低对比度结构检测构成突出挑战 [3]。传统去噪依赖 BM3D、NLM 等手工先验 [2]，近年来深度学习方法在医学图像去噪中取得突破 [6, 1, 5, 4]。

现有研究的一个普遍问题是不同模型的对比在不等条件下进行——数据划分、训练步数、预处理各异，性能差异无法唯一归因于架构本身。本报告在严格变量控制下，回

答在约 600 例 UKB T1 去噪任务下的最优训练配置是什么。

1.2 任务与噪声参数

课程提供约 600 例 UK Biobank T1 加权结构像。每例含参考干净图像（原始 T1）与人工加噪图像，在干净图像上注入 Rician+ 高斯混合噪声生成。由 manifest.csv 记录：高斯分量标准差比例均值 0.025 ± 0.008 ，Rician 分量标准差比例均值 0.026 ± 0.008 ，每例独立采样，构成病例自适应非均匀噪声。

所有实验使用统一的预处理管线：原始 T1 经三线性插值重采样至 $128 \times 128 \times 128$ 各向同性分辨率，随后在脑组织掩膜（强度 > 0 ，基于干净图生成）内按逐三维体素的第 1-99 百分位进行独立线性归一化至 $[0, 1]$ （含噪图与干净图分别缩放）。独立百分位归一化的优势在于使干净图保持完整的灰度动态范围，有利于模型学习更精确的残差映射；代价是丢失了图像灰度的绝对物理意义——不同病例之间不再具有统一的强度标尺，仅适用于配对训练与评估的闭环场景。训练时从轴向提取 2D 切片，有效切片过滤阈值 5%（组织像素占全图像素比例 $> 5\%$ 的切片保留，低于者丢弃）。

1.3 评价指标与计算方式

采用组织掩膜内计算（本文称其为 tissue-only 口径）是神经影像领域（MICCAI、ISBI、NeuroImage、IEEE TMI 等）的通用标准。颅骨外背景区域信号接近零，Rician 噪声方差极大，若纳入计算会大幅拉低全图 PSNR 基线、导致增益数值虚高，且背景区域无临床与科研价值。

以下统称组织掩膜内计算口径为 tissue-only 口径。 p 为预测， t 为干净参考， $\mathcal{M} = \{\text{像素} \mid t > 10^{-6}\}$ 为脑掩膜，各指标定义如下：

- MSE（均方误差，Mean Squared Error）：衡量预测图像与参考图像像素差值平方的平均值，对大误差更敏感。仅脑组织像素参与均值计算，公式为：

$$\text{MSE} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} (p_i - t_i)^2$$

- PSNR（峰值信噪比，Peak Signal-to-Noise Ratio）：基于 MSE 衡量图像整体保真度，单位为分贝（dB），数值越高代表去噪效果越好。 $[0, 1]$ 归一化下 $\text{data_range} = 1.0$ 对应归一化范围，公式为：

$$\text{PSNR} = 20 \log_{10}(1) - 10 \log_{10}(\text{MSE})$$

- PSNR 增益：去噪后 PSNR 相对含噪输入 PSNR 的提升量，用于直接衡量去噪算法的净收益。公式为：

$$\text{Gain} = \text{PSNR}_{\text{pred}} - \text{PSNR}_{\text{noisy}}$$

全报告默认口径为逐切片组织-PSNR 后取有效切片均值。

- MAE (平均绝对误差, Mean Absolute Error): 衡量预测图像与参考图像像素差值绝对值的平均值, 反映整体平均偏差的大小。仅脑组织像素内计算, 公式为:

$$\text{MAE} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} |p_i - t_i|$$

- RMSE (均方根误差, Root Mean Square Error): MSE 的平方根, 量纲与原始信号强度一致, 直观反映误差的典型幅度。仅脑组织像素内计算, 公式为:

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} (p_i - t_i)^2}$$

- ME (平均误差, Mean Error): 衡量预测图像与参考图像像素差值的均值, 可反映整体强度的系统性高估或低估。正值表示高估强度, 负值表示低估, 仅脑组织像素内计算, 公式为:

$$\text{ME} = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} (p_i - t_i)$$

- SSIM (结构相似性指数, Structural Similarity Index Measure): 从亮度、对比度、结构三个维度衡量两幅图像的结构相似程度, 取值范围 $[0, 1]$, 越接近 1 代表结构保真度越好。采用 11×11 高斯窗, $K_1 = 0.01$, $K_2 = 0.03$, 全图计算。SSIM 基于局部滑动窗口计算结构相似性, 若强制剔除背景会破坏窗口完整性、引入边界伪影, 因此行业内通常保留全图计算; 其数值仅用于模型间相对排序, 不与 PSNR 做绝对值对比。

1.4 本文贡献

1. 建立“三层递进评估 + 一层全量验证”的分层实验框架, 以严格变量控制在课程算力下完成系统模型遴选。前两层为精度筛选, 第三层为跨种子稳定性评估 (不做淘汰, 为最终选型提供多维度证据)。
2. 以 NLM 为传统基线, 量化深度学习方案的绝对提升倍数。
3. 通过 ME 指标追踪 Rician 正偏差的校正轨迹, 结合信号强度分箱验证噪声在脑组织内部的信号依赖性。
4. 系统评估 SE 通道注意力机制的增益幅度与跨种子稳定性代价。

2 实验设计

2.1 递进实验框架

实验按“三层递进评估 + 一层全量验证”组织 (表 1)。Stage A/B/C 所用数据子集均从全量训练集中抽取, 与最终独立测试集无任何重叠, 不存在数据泄露。

表 1: 递进实验设计概览

层级	阶段内容	数据	步数
评估层 1	Stage A (损失消融): 纯 L1 vs. L1+0.2(1-SSIM)	65 例 (80/20)	1500
评估层 2	Stage B (架构筛选): 5 类架构同条件对比	120 例 (80/20)	1500
评估层 3	Stage C (稳定性): 全部 Tier-1 模型各 3 种子验证	120 例 (80/20)	1000×3
全量层	Stage D: 全部 Tier-1 候选在 80/10/10 划分上全量训练, 独立测试集输出	600 例	5000

2.2 核心训练协议

Python、NumPy、PyTorch (含 CUDA 确定性) 及 DataLoader 均固定 seed 42 (Stage C 额外 seed 123、456)。实验环境: 训练 GPU NVIDIA A10 (24 GB), Ubuntu 22.04, CUDA 12.8.1, Python 3.12.13, PyTorch 2.10.0 (GPU 后端)。优化器 AdamW ($lr=10^{-3}$, $wd=10^{-5}$, $\beta=(0.9, 0.999)$), 无学习率调度。统一 batch size 8, 训练时 50% 概率水平翻转。模型采用残差学习 $\hat{x} = \text{clip}(x - \hat{n}, 0, 1)$ 。step 模式每 75 步评估一次验证集。全流程 (Stage A-D) 顺序执行, 实测 GPU 总时间约 2.3 小时 (stage A 6 min + stage B 25 min + stage C 52 min + stage D 54 min)。Stage A 后锁定损失为纯 L1。

在架构实现上, 所有 U-Net 系列模型统一采用: 2×2 最大池化下采样、 2×2 转置卷积上采样; 每个卷积块由两次 3×3 卷积 + BatchNorm + ReLU 组成; 编码器共 4 层、解码器 4 层加瓶颈层 (总深度 5 层); 输入输出均为 128×128 单通道灰度。预处理中脑组织掩膜基于干净图强度 > 0 判定, 归一化前后顺序为: 先插值至 128^3 , 再在掩膜内做百分位归一化。

关于训练损失口径, L1 项仅在脑组织像素 ($\text{target} > 0$) 内计算, 与评估的 tissue-only 口径完全对齐, 可屏蔽无临床意义的背景噪声对优化方向的干扰; SSIM 项基于滑动窗口统计, 强制裁剪掩膜会破坏窗口内统计有效性并引入边界伪影, 因此采用全图计算, 且背景区域结构平滑, 对总损失权重贡献有限。复合损失权重 0.2 为医学图像去噪任务的常用经验取值 [5, 6], 本次消融仅验证该权重下的效果; Stage A 后锁定损失为纯 L1。

2.3 模型架构

共同骨架: 所有 U-Net 系列模型共享编码器 - 解码器骨架, 已在第 2.2 节详述 (2×2 最大池化下采样、 2×2 转置卷积上采样, 卷积块由 $\text{Conv}3 \times 3 + \text{BN} + \text{ReLU} \times 2$ 组成, 4 层编码器 + 瓶颈 + 4 层解码器共 5 层深度)。以下分别说明各模型相对于共同骨架的差异。

U-Net (32ch / 64ch) [5]: 标准 U-Net, 无结构修改。首层编码器通道数为 `base_channels` (32 或 64), 每加深一层通道数翻倍, 解码器对称缩减。U-Net 32ch 参数量 7.76M, U-Net 64ch 参数量 31.04M。

UNet++ Lite [8]: 基于 UNet++ 的轻量变体（移除深度监督分支，保留嵌套密集跳连）。核心特征：同一分辨率层级上的所有编码器节点和所有前置解码器节点，均通过跳连路径将特征图级联至当前解码器节点，形成多条短梯度路径，加速深层梯度回传。2.00M 参数（远少于 U-Net 32ch，因精简后的多路径节点共享浅层特征、未显著增加通道数）。

RED-CNN [1]: 对称残差编码器 – 解码器，原为低剂量 CT 去噪设计。5 层卷积堆栈，每层由 $\text{Conv}3 \times 3 + \text{ReLU}$ 组成（编码器 96 通道，无池化而用步长卷积实现下采样，感受野线性增长）；解码器使用转置卷积恢复分辨率，输入到输出端添加残差连接。1.02M 参数。

SE-UNet (32ch) [4]: 在 U-Net 32ch 骨架的编码器第 2–4 层及瓶颈层的每个卷积块之后嵌入 SE 通道注意力模块，共 4 个模块；解码器各层不使用 SE 模块。每模块：全局平均池化压缩空间信息 $\rightarrow$ FC（缩减比 $r=8$ ，瓶颈通道数 $= \max(\text{ch}/8, 4)$ ） $\rightarrow$ ReLU $\rightarrow$ FC $\rightarrow$ Sigmoid 门控生成逐通道缩放权重，与原始特征图逐通道相乘。以仅 +0.09M 参数增量（+1.1%）引入通道注意力。7.85M 参数。

3 实验结果与分析

3.1 全局汇总

表 2 汇报全部四阶段实验结果（所有数据均为 tissue-only 口径）。 2σ 值来自 Stage C 中期训练（1000 步，3 种子）的跨种子波动度量，不代表全量 5000 步收敛后的长期方差。Stage B 中仅前四名满足 $\Delta \leq 0.1 \text{ dB}$ 的 Tier-1 标准，RED-CNN 因 $\Delta = 0.16 \text{ dB}$ 进入 Tier-2，未进入后续 Stage C/D。

表 2: 四阶段完整实验结果汇总（tissue-only 口径）

阶段	模型/配置	训练例	步数	Val Gain	Test Gain	$2\sigma^*$
A	L1 Only	52	1500	2.32	–	–
A	L1 + 0.2(1–SSIM)	52	1500	1.21	–	–
B	SE-UNet (32ch)	96	1500	2.63	–	Tier-1
B	UNet++ Lite	96	1500	2.62	–	Tier-1
B	U-Net 32ch	96	1500	2.58	–	Tier-1
B	U-Net 64ch	96	1500	2.57	–	Tier-1
B	RED-CNN	96	1500	2.47	–	Tier-2
C	UNetPP Lite (3 seeds)	96	1000 $\times$ 3	2.42	–	0.17
C	U-Net 32ch (3 seeds)	96	1000 $\times$ 3	2.41	–	0.19
C	U-Net 64ch (3 seeds)	96	1000 $\times$ 3	1.91	–	0.82

阶段	模型/配置	训练例	步数	Val Gain	Test Gain	$2\sigma^*$
C	SE-UNet 32ch (3 seeds)	96	1000×3	1.92	—	1.77
D	SE-UNet (32ch)	480	5000	2.79	2.77	—
D	U-Net 64ch	480	5000	2.77	2.72	—
D	U-Net 32ch	480	5000	2.72	2.68	—
D	UNet++ Lite	480	5000	2.29	2.28	—

* 2σ 来自 Stage C 中期训练（1000 步，3 种子）的跨种子波动，不代表全量收敛后的长期方差。

3.2 传统基线对比：NLM

NLM(非局部均值, Non-Local Means)是传统图像去噪领域的经典算法,通过在图像内搜索相似邻域块并进行加权平均来抑制噪声,是医学影像去噪任务中广泛使用的传统方法基线。以 skimage NLM ($h = 1.15 \hat{\sigma}$, fast_mode, patch_size= 5, patch_distance= 6) 为传统参照。 $\hat{\sigma}$ 基于图像局部方差鲁棒估计得到; patch_distance 对应搜索窗口半径 6 像素; NLM 与深度学习模型一致,采用逐 2D 轴向切片处理。NLM 在 60 例测试集上的 tissue-only 3D PSNR 为 46.21 dB,增益 = 0.81 ± 0.29 dB。深度学习推荐方案(U-Net 32ch, test gain = 2.68 dB)提升至其 3.3 倍。NLM 参数基于经验公式选取,结果代表传统方法的合理基线水平,与同类 2D 深度学习去噪方法在相近噪声水平下的表现大致可比;若采用 3D 卷积架构参考 [7] 的结果,预计可获得 0.2-0.4 dB 的进一步提升。

3.3 Stage A: 损失函数消融

在 52 训练 + 13 验证例、1500 步条件下,纯 L1 损失 val gain 达到 2.32 dB,而 L1+0.2(1-SSIM) 组合损失仅为 1.21 dB,差距达 1.11 dB。




图 1: 损失函数消融实验 (a) PSNR Gain 对比 (b) 训练曲线

该结果与直觉相反——通常认为感知约束 (SSIM) 能提供结构先验从而辅助收敛,

但在本任务中产生了显著的负面效应。需注意：SSIM 权重 0.2 为常用经验取值，本次消融仅验证该权重下的效果，不排除其他权重下复合损失存在提升空间。

现象的可能原因有三层。其一，SSIM 基于 11×11 滑窗内的局部均值和方差统计量，在 Rician 噪声主导的低信号区域，局部信号方差与噪声方差高度耦合，导致 SSIM 对真实结构退化和噪声波动的区分力不足，梯度偏向平滑噪声纹理而非恢复解剖边界。其二，本任务为严格配准的配对去噪场景，含噪图像与干净图像的解剖结构完全一致，仅存在像素级噪声扰动，不存在结构退化——SSIM 作为结构相似性指标，无法提供额外的结构先验引导，其梯度仅作用于噪声平滑，与 L1 的像素级去噪目标冗余甚至冲突。其三，也是这里差距较大的主要原因：复合损失中 L1 项采用 tissue-only 口径、SSIM 项采用全图口径，两者优化目标的空间范围不匹配，会在一定程度上加剧梯度冲突。但是在调整至现有口径之前，我已在全局统一口径下完成过同条件的 Stage A 消融实验，旧版结果图显示纯 L1 损失的验证增益仍优于 L1+SSIM 复合损失，仅性能差距缩小至约 0.37 dB。这说明“纯 L1 更适配本任务”是稳健结论，不受口径选择的影响；当前采用分口径设置的原因（已在第 1.3 节（SSIM 全图计算的口径理由）和第 2.2 节（训练损失口径对齐）中说明，这里不再赘述。因此根据本阶段实验的结果可以认为，纯 L1 损失更适配本任务，后续实验全部采用纯 L1 损失。

3.4 Stage B：架构筛选

5 类架构在 96 训练 + 24 验证例、1500 步的同条件下对比（图 2），结果呈极高密度的性能分布。




图 2: 架构筛选结果（120 例，1500 步）(a) PSNR Gain 对比 (b) 训练曲线

图 2a 显示：SE-UNet (32ch) 以 2.63 dB 领跑，UNet++ Lite (2.62 dB)、U-Net 32ch (2.58 dB)、U-Net 64ch (2.57 dB) 紧咬其后，四者极差仅 0.06 dB，均满足 Tier-1 标准（与第一名差距 ≤ 0.1 dB）。RED-CNN 以 2.47 dB 垫底， $\Delta = 0.16$ dB 超过 Tier-1 阈值，被划入 Tier-2，不进入 Stage C 和 Stage D。

就 SE 通道注意力的贡献而言，SE-UNet (32ch) 仅以 +0.09M 参数 (+1.1%) 代价

取得 0.05 dB 的微弱领先，说明 SE 注意力在 T1 去噪中存在可检测但幅度有限的正面贡献。

UNet++ Lite 的参数效率值得关注：以 2.00M 最少参数量（仅为 U-Net 32ch 的 25.7%）达到 2.62 dB 的次优性能，其嵌套密集跳连设计提供了多条短梯度路径，在 1500 步这样的短步长下收敛速度显著快于标准 U-Net，使其在这一训练阶段表现占优。

对比 U-Net 32ch 与 64ch，4 倍参数量差距仅换来 -0.01 dB 的性能差异（统计不可分辨），说明在 1500 步预算下 32 个基础通道已提供足够的表示容量。

RED-CNN 性能较弱，可能因为其在 5 层编码器中使用 3×3 卷积堆栈，感受野增长线性而 U-Net 系列通过池化实现指数级感受野扩张，在全局噪声分布建模上处于劣势。

图 2b 的训练曲线展示了收敛动态：SE-UNet 和 U-Net 32ch（实线）在 400 步后持续拉开与其余模型的差距，UNet++ Lite（虚线）训练初期领先但随后增速放缓。在 120 例、1500 步的预算下，全部 Tier-1 候选性能分布极窄，需要 Stage C 的跨种子重复实验提供额外判别信号。

本报告所有实验采用等步数比较——回答”相同训练预算下最优”的问题，而非各模型充分收敛后的理论上限。固定 epoch 会使大模型消耗更多算力，不适合资源受限场景。在本次总 GPU 时间约 2.3 小时的预算下，资源投入应视为建模成本的一部分；需要说明的是，U-Net 64ch 可能存在在 1500 步下训练不充分而性能被低估的情形，若获得更多步数有可能释放其容量优势，但在给定的固定预算约束下这一成本无法被忽略。

3.5 Stage C：稳定性验证

Stage C 对四种 Tier-1 模型进行中期训练（1000 步 $\times$ 3 种子）的独立重复（图 3，表 3）。




图 3: 跨种子稳定性验证（120 例，1000 步）(a) 3 种子 PSNR Gain，虚线为均值 (b) 收敛轨迹

图 3 和表 3 共同揭示了三类跨种子行为模式（注意 Stage C 与 Stage B 的训练步数不同，均值绝对值不直接可比，稳定性分析聚焦于种子间离散度而非均值本身）：

表 3: Stage C 中期稳定性结果汇总 (1000 步, 3 种子, tissue-only 口径)

模型	Seed 42	Seed 123	Seed 456	Mean	Std	2σ
UNetPP Lite	2.33	2.44	2.50	2.42	0.08	0.17
U-Net 32ch	2.38	2.34	2.52	2.41	0.09	0.19
U-Net 64ch	1.46	2.26	2.02	1.91	0.41	0.82
SE-UNet 32ch	2.43	0.90	2.43	1.92	0.89	1.77

第一类为高稳定性组, 包括 UNet++ Lite 和 U-Net 32ch, 两者跨种子标准差均 ≤ 0.09 dB, 2σ 分别仅 0.17 dB 和 0.19 dB, 图 3b 中六条训练曲线紧密聚合, 可复现性优秀。

第二类为中不稳定组——U-Net 64ch, 跨种子 $2\sigma = 0.82$ dB, Seed 42 仅获 1.46 dB 与 seed 123 的 2.26 dB 相差 0.80 dB。核心原因是 1000 步预算对 31.04M 参数的大模型严重不足, 不同随机种子停留在差异巨大的鞍点或局部极小值。

第三类为训练失效组——SE-UNet (32ch), seed 123 下 val gain 仅 0.90 dB, 不到其他两个种子 (2.43、2.43 dB) 的 40%。图 3b 中 seed 123 轨迹在约 400 步后停滞于 1.0 dB 以下, 训练损失同步在高位停滞、无下降趋势, 与梯度消失的特征吻合。推测机制为: SE 模块中 Sigmoid 门控在随机初始化时, 若 GAP 压缩向量落入 Sigmoid 饱和区, $a(1-a) \approx 0$ 导致门控梯度消失, 通道注意力退化且额外引入参数噪声, 扰动跳跃连接梯度路径。该现象仅在 1000 步中期训练中观测到; 5000 步全量训练中 seed 42 未出现失效, 不排除更长训练步数下部分失效种子可自行恢复。本次 3 种子观测中出现 1 例训练失效, 提示该架构存在初始化敏感的收敛失败风险; 实际使用时建议增加跨种子验证以规避此风险。

3.6 Stage D: 全量训练

全量训练使用 480 训练 + 60 验证 + 60 测试, 所有 Tier-1 模型统一跑满 5000 步。

图 4 展示 SE-UNet 和 U-Net 64ch 以相近速率交替领先, 在约 3500 步后增速显著放缓; UNet++ Lite 的曲线从第一个评估点 (step 250, 增益 2.29 dB) 后便急剧下降并在约 0.3–0.5 dB 的低位持续震荡, 与其他三者持续上升的轨迹形成鲜明对比。

表 4: Stage D 全量训练结果 (5000 步, seed 42, tissue-only 口径)

模型	Val Gain [†]	Test Gain	Test PSNR	Test SSIM	Test MAE	Test ME	参数量
SE-UNet (32ch)	2.79	2.77	48.23	0.9959	0.00290	-3.1×10^{-4}	7.85M
U-Net 64ch	2.77	2.72	48.19	0.9956	0.00293	-7.4×10^{-5}	31.04M
U-Net 32ch	2.72	2.68	48.14	0.9954	0.00295	-5.8×10^{-5}	7.76M
UNet++ Lite	2.29	2.28	47.74	0.9923	0.00316	$+1.1 \times 10^{-4}$	2.00M

[†] 所有模型均报告验证集最优 checkpoint (best.pt) 的增益; UNet++ Lite 的最优 checkpoint 位于 step 250。




图 4: 全量训练验证曲线 (480 训练例, 5000 步), test 结果见表 4

表 4 揭示了全量训练下的关键现象。

SE-UNet 稳居数值最优但优势微小: test gain 2.77 dB, 相比 U-Net 32ch (2.68 dB) 仅高出 0.09 dB, 在 Tier-1 候选间统计不可分辨。SE 注意力在 5000 步充足训练下带来了微弱但全维度一致的提升。

U-Net 64ch 的高参数量回报极低: 4 倍参数量 (31.04M vs. 7.76M) 仅换取 +0.05 dB test gain 改善。在 128^2 切片分辨率下, 32 个基础通道已触及 U-Net 架构的表示容量上限。Stage C 中其跨种子 $2\sigma = 0.82$ dB, 亦处于可控但非最优水平——参数量膨胀既未带来精度突破, 也未改善训练稳定性。

综合 Stage B/C/D 的完整轨迹可见 SE 注意力的双重效应: 在 Stage B (+0.05 dB) 和 Stage D (+0.09 dB) 中均以微弱优势领先, 方向一致且随步数增加呈加深趋势, 证明了通道注意力在 T1 去噪中的真实贡献; 然而 Stage C 中期观测中 seed 123 的训练失效 (0.90 dB, $2\sigma = 1.77$ dB) 揭示了其潜在的收敛敏感性。推测机制为: Sigmoid 门控在训练早期落入饱和区导致梯度消失, 退化后的 SE 参数充当参数噪声源, 扰动跳跃连接梯度路径。该效应仅在 1000 步中期训练中观测到; 5000 步 seed 42 正常收敛, 不排除更长步数下失效种子可部分恢复。

UNet++ Lite 则出现了容量与数据规模严重错配导致的泛化坍塌——验证曲线在 step 250 达到峰值 (gain 2.29 dB) 后持续下跌至约 0.3–0.5 dB 并低位震荡。这一先升后崩的模式并非欠拟合 (欠拟合通常收敛至稳定次优值)。根本原因是 2M 参数量不足以编码 480 例全量数据的解剖分布多样性: step 250 时模型仅接触约 30–40 个病例的切片 ($\approx$ 全量数据的 6%), 能在有限病例上形成有效去噪映射; 随着训练暴露更多新样本, 模型无法在有限参数空间内同时拟合所有分布, 已学到的映射被持续覆盖。此现象从 Stage B 到 Stage D 的全程视角来看, 是收敛速度差异和容量上限差异两个独立因子交替主导的结果——1500 步时嵌套密集跳连的短梯度路径使其收敛速度远超 U-Net, 因而排名靠前; 5000 步后容量上限成为瓶颈, 2M 参数对 480 例数据的覆盖能力达到硬上

限。数据量从 120 例扩充至 480 例后最优验证增益不升反降（2.62 dB $\rightarrow$ step 250 快照 2.29 dB），核心源于验证集同步扩大导致泛化误差暴露与训练集解剖多样性超出模型容量的双重作用。其 test ME 为唯一正值（ $+1.1 \times 10^{-4}$ ），暗示部分区域保留了原始 Rician 正偏差。该现象对模型遴选有直接启示：筛选阶段的数据规模与训练步数需与最终目标场景匹配；若筛选集远小于全量数据，小模型会因收敛速度优势被高估，最终全量训练时出现性能反转。

在跨模型一致性方面，SSIM 在 0.9923–0.9959 的极窄区间内（极差 0.0036），判别力接近天花板；MAE 排序与 PSNR 完全一致，验证了指标间的内在协调性。

3.7 最终推荐方案




图 5: U-Net 32ch（推荐方案）在独立测试集（n=60）上的去噪性能

综合全部四阶段实验证据（图 5，表 4）：

- SE-UNet (32ch) 在 seed 42 下精度最优（48.23 dB），但 Stage C 中期观测到 seed 123 训练失效（ $2\sigma = 1.77$ dB），存在初始化敏感的收敛失败风险。
- U-Net 64ch 以 4 倍参数量仅换得 +0.05 dB 精度改善，参数效率极低，跨种子波动亦非最优（ $2\sigma = 0.82$ dB）。
- UNet++ Lite 全量数据下出现容量 – 数据错配——验证增益从 step 250 的 2.29 dB 崩溃至训练终点 0.3–0.5 dB，2M 参数容量无法适配 480 例数据规模。
- U-Net 32ch 在所有维度均衡——精度仅落后 0.09 dB（统计不可分辨），中期训练跨种子 $2\sigma = 0.19$ dB（可复现性优异），7.76M 参数适中。

综合以上证据，本报告推荐 U-Net 32ch 为最终方案。选型依据是跨种子稳定性与可复现性——精度维度在 Tier-1 候选间统计不可分辨，而稳定性维度提供了关键的区分信号。跨种子稳定性直接决定实验的可复现性与工程落地成本：U-Net 32ch 的低波动 ($2\sigma = 0.19$ dB) 意味着单次训练即可获得稳定可靠的结果，无需多次重复筛选最优种子，在资源受限的科研场景与批量部署中具有更高的实用价值。稳定性结论基于 Stage C 中期训练（1000 步）观测，全量收敛后的长期稳定性仍待进一步验证。

3.8 病例可视化与定性分析




图 6: 测试集定性可视化 (U-Net 32ch) (a) 最佳增益 (b) 最低增益 (c) 中位增益病例

以 U-Net 32ch 对测试集 60 例进行推理，提取增益最高、最低及中位病例进行定性可视化（图 6）。每幅子图自上而下三行：含噪输入、去噪输出与干净参考的原始图像，三者局部放大细节（聚焦灰白质交界或脑沟/脑回结构），以及去噪误差图、梯度 - 误差联合图（梯度模 $>$ 阈值品红着色）和含噪误差图；所有误差图使用统一的 $[-0.08, 0.08]$ 色彩映射范围。

最佳增益病例（图 6a）：该病例（3D gain ≈ 3.90 dB）初始含噪图像中灰白质边界和皮层沟回处存在明显的结构模糊。去噪后这些高对比度解剖边界得到清晰恢复，局部放大细节中去噪输出与干净参考的差异肉眼难辨。绝对误差图显示误差几乎全部集中在解剖边界和脑沟区域；梯度 - 误差联合图进一步揭示：这些边界区域的梯度模较大（品红高亮），而平滑均匀区（白质内部）梯度极小且对应误差接近零——模型在解剖结构变化剧烈处仍有可观测的残留误差，但在均匀组织内部实现了近乎完美的恢复。

最低增益病例（图 6b）：该病例（3D gain ≈ 0.77 dB）的初始含噪图像 PSNR 极高 (≈ 50.31 dB)，含噪图在视觉上与干净参考几乎无异。这不是模型失效，而是度量天花

板效应：当噪声极小时，PSNR gain 的计算空间被压缩。该病例的存在也说明数据集内噪声水平的病例间差异显著（标准差比例范围 0.013–0.042）。

中位病例（图 6c）：误差模式同样集中于灰白质交界和皮层沟回处，深部白质核心和脑室附近误差极低——与 T1 的组织信号分布一致。所有去噪输出均未引入可见的结构伪影，残差学习在纹理保真度上具有明显优势。

3.9 信号强度分箱——Rician 信号依赖性的实证验证

按脑组织掩膜内干净图强度将全部 6602 个有效切片三等分，所有 PSNR/ME 口径与主表一致（tissue-only）。图 7 以柱高表示各分区 PSNR Gain，红色/蓝色标注分别对应含噪 ME 和预测 ME 的方向及量级。




图 7: 信号强度分箱分析（tissue-only 口径），定量结果见表 5

表 5: 脑组织内信号分箱定量结果（tissue-only 口径，U-Net 32ch 输出）

信号区间	切片数	组织均值	PSNR	Gain	Pred ME	Noisy ME
低信号（CSF/边缘）	803	[0.01, 0.12)	51.67	6.72	-3.4×10^{-4}	$+3.5 \times 10^{-3}$
中信号（灰质）	4765	[0.12, 0.28)	47.94	2.36	-3.1×10^{-4}	$+1.6 \times 10^{-3}$
高信号（白质）	1034	[0.28, 0.38]	46.92	1.58	-3.3×10^{-4}	$+1.2 \times 10^{-3}$

图 7 和表 5 共同提供了 Rician 噪声信号依赖性的直接实证。

在增益与组织信号强度的关系上，低信号区 $\text{gain } 6.72 \text{ dB} \approx \text{中信号区 } 2.36 \text{ dB} \times 2.8 \approx \text{高信号区 } 1.58 \text{ dB} \times 4.3$ 。该梯度方向与 Rician 噪声的数学特性完全一致——Rician 幅度在低信号时的噪声方差远大于高信号时。中信号区贡献了 72% 的切片数且 $\text{gain } 2.36 \text{ dB}$ ，其加权平均决定了全局增益的主要量级。分箱增益的加权均值与全局 $\text{test gain } (2.68 \text{ dB})$ 存在约 0.1 dB 的细微差异，源于分箱边界的切片划分方式，整体趋势完全吻合。

含噪 ME 精确追踪了 Rician 偏差：含噪 ME 从 $+3.5 \times 10^{-3}$ (低) 单调降至 $+1.6 \times 10^{-3}$ (中) 和 $+1.2 \times 10^{-3}$ (高)，随信号减弱而增大，与 Rician 偏差 - 信号反比关系吻合。

模型统一校正了 Rician 正偏差，残留微弱全局低估。去噪后三个分区 ME 一致转负且量级压缩至约 -3.1×10^{-4} ，幅度较含噪 ME 缩小约 7 倍。残留的微弱负偏差与 L1 损失的统计特性直接相关：L1 损失引导模型预测趋近于信号的条件中位数，而 Rician 噪声为右偏分布，其中位数天然小于信号均值，因此 L1 优化会系统性产生轻微低估。该偏差是 L1 损失的固有特性，量级远小于原始 Rician 正偏差，对后续影像分析无实质影响。三个分区去噪后 ME 几乎一致，说明 L1 loss 在组织掩膜内的全局优化对不同信号强度区域的偏差校正具有均匀性。

低信号区的极高增益需谨慎解读：低信号区仅 803 个切片 (12%)，干净图强度极低 ($[0.01, 0.12]$)，噪声波动可能超过信号本身。 6.72 dB 的超高增益部分反映了该区域基线 PSNR 极低，模型通过简单平滑 CSF 区域即可获得较大 MSE 降低——这与 Rician 特性一致，并不完全等价于恢复了精细结构。

低信号区噪声方差大、结构辨识度低的特性，也恰好解释了 Stage A 中复合损失的失效——SSIM 在增益最高的低信号区无法提供有效梯度引导，反而拖慢整体收敛。

综合以上分析，本工作虽未针对 Rician 噪声进行专项校正，但通过 ME 指标和信号分箱进行了系统追踪，三条证据链共同确认了 Rician 信号依赖性的真实存在且被模型有效学习：(1) 分箱 gain 梯度 $6.72 \rightarrow 2.36 \rightarrow 1.58 \text{ dB}$ 与 Rician 方差 - 信号关系吻合；(2) 含噪 ME 从 $+3.5 \times 10^{-3}$ 单调降至 $+1.2 \times 10^{-3}$ ；(3) 去噪后 ME 全局收束至 -3.1×10^{-4} ，表明通用 L1 残差学习已能有效压制 Rician 正偏差。需注意 ME 仅反映全局均值偏移，无法区分组织类型或空间位置的偏差异质性。

3.10 参数效率权衡

图 8 将 Stage B 中五种架构的参数—性能权衡可视化，揭示了三条不同的设计路径。

极限参数效率路径以 UNet++ Lite 为代表：2.00M 参数在 Stage B 达到 2.62 dB ，单位参数增益 1.31 dB/M ，是 U-Net 32ch (0.33 dB/M) 的 4.0 倍。但其全量训练中性能崩溃至 $0.3\text{--}0.5 \text{ dB}$ （最终 $\text{test gain } 2.28 \text{ dB}$ 来自早期 snapshot，不代表稳定收敛），表明极稀疏参数化下性能与数据规模的良性扩展存在硬上限。

稳健均衡路径以 U-Net 32ch 为代表：7.76M 参数，跨阶段表现最一致——Stage B 2.58 dB 、Stage C $\mu = 2.41 \text{ dB}$ 、Stage D 2.68 dB 。其参数—性能—稳定性三角均衡是当




图 8: 参数—性能权衡 (Stage B, 1500 步)

选最终推荐方案的根本原因。

容量浪费路径以 U-Net 64ch 为代表：31.04M 参数 ($\times 4$)，Stage B gain 仅 2.57 dB (-0.01 dB vs. 32ch)。在固定步数预算下，超大参数量使每个参数获得更少的梯度更新，等效于训练不充分。

注意力增强路径以 SE-UNet (32ch) 为代表：以仅 $+1.1\%$ 参数增量 ($+0.09$ M) 取得 $+0.05$ dB 增益。挑战不在参数量，而在稳定性。

RED-CNN (1.02M, 2.47 dB) 参数最少但增益也最低，说明其 5 层对称 3×3 卷积堆栈的表示效率低于 U-Net 系列的编码器 - 解码器架构。

UNet++ Lite 的参数效率也印证了效率的场景依赖性：小样本阶段其极高参数效率本质是短梯度路径带来的收敛速度优势 + 容量与 120 例数据的匹配；当数据量与训练步数同时扩展至 480 例 $\times$ 5000 步，收敛速度红利消失、容量短板暴露，参数效率优势便不复存在。

3.11 局限与展望

1. 2D 切片逐层处理未利用 z 轴层间连续性，3D 卷积或 2.5D 多切片输入预期可获得额外增益 [7]。
2. 结论仅基于 T1 加权与单次数据划分 (80/10/10, seed 42)，泛化性待交叉验证确认。
3. Stage C 仅覆盖 3 个种子，更大规模 (≥ 10) 的种子扫描将提供更可靠的稳定性估计。

4. 跨种子稳定性结论基于 1000 步中期观测，全量 5000 步下的长期波动需进一步验证。
5. 信号分箱使用简单的三等分，组织类别特异性分析（如经 FSL FAST 分割）可提供更精细的见解。

4 结论

本报告通过“三层递进评估 + 一层全量验证”的框架，对 UK Biobank T1 脑 MRI 去噪任务进行了系统的训练配置遴选。

在损失函数层面，纯 L1 损失（tissue-only 口径）以 val gain 2.32 dB 显著优于 L1+SSIM 组合（1.21 dB），Rician 噪声下 SSIM 的信号 - 噪声区分力不足、结构先验冗余以及优化空间不匹配共同导致复合损失失效。

在架构层面，五类候选经三层递进筛选后的最终结果为：SE-UNet 以 test PSNR 48.23 dB（gain 2.77 dB）取得数值最优，但中期跨种子观测暴露出 1 例训练失效（ $2\sigma = 1.77$ dB），SE 通道注意力以 +1.1% 参数增量换取 +0.09 dB 增益的代价是收敛敏感风险；UNet++ Lite 以 2.00M 最少参数量在 Stage B 取得 2.62 dB，但在全量 480 例 $\times$ 5000 步下因容量 - 数据错配发生泛化坍塌，验证增益从 step 250 的 2.29 dB 崩溃至训练终点 0.3–0.5 dB，揭示了筛选阶段小样本高估偏差与容量上限的双重约束。综合权衡后，U-Net 32ch 以 test PSNR 48.14 dB（gain 2.68 dB）和 mid-training 跨种子 $2\sigma = 0.19$ dB 实现精度 - 稳定性最优折衷，较 NLM 传统基线（gain 0.81 dB）提升 3.3 倍。

信号分箱与 ME 追踪进一步揭示 Rician 噪声的信号依赖性——增益梯度从低信号区的 6.72 dB 递减至高信号区的 1.58 dB，去噪后 ME 全局收束至 -3.1×10^{-4} ，证实通用 L1 残差学习已能有效压制 Rician 正偏差的主体成分。

全文实验基于 Ubuntu 22.04 + CUDA 12.8.1 + PyTorch 2.10 环境，“三层递进评估”框架以总 GPU 时间约 2.3 小时完成一次完整闭环，实验日志、中间结果和最终输出均可通过固定种子与预置脚本完整复现。

参考文献

- [1] Hu Chen, Yi Zhang, Weihua Zhang, Peixian Liao, Zhen Li, Jiliu Zheng, and Ge Wang. RED-CNN: A convolutional neural network for low-dose CT via residual encoder-decoder. In *Medical Image Computing and Computer Assisted Intervention (MICCAI)*, pages 510–518, 2017.
- [2] Kostadin Dabov, Alessandro Foi, Vladimir Katkovnik, and Karen Egiazarian. Image denoising by sparse 3-D transform-domain collaborative filtering. *IEEE Transactions on Image Processing*, 16(8):2080–2095, 2007.

- [3] Hákon Gudbjartsson and Samuel Patz. The Rician distribution of noisy MRI data. *Magnetic Resonance in Medicine*, 34(6):910–914, 1995.
- [4] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(8):2011–2023, 2019.
- [5] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *MICCAI*, pages 234–241, 2015.
- [6] Kai Zhang, Wangmeng Zuo, Yunjin Chen, Deyu Meng, and Lei Zhang. Beyond a Gaussian denoiser: Residual learning of deep CNN for image denoising. *IEEE Transactions on Image Processing*, 26(7):3142–3155, 2017.
- [7] Xue Zhao, Jian Li, Zhen Jiang, Hu Chen, and Lei Zhang. Denoising of volumetric magnetic resonance imaging using multi-channel three-dimensional convolutional neural network. *Quantitative Imaging in Medicine and Surgery*, 11(8):3771–3785, 2021.
- [8] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. UNet++: A nested u-net architecture for medical image segmentation. *IEEE Transactions on Medical Imaging*, 39(6):1856–1867, 2020.

附录

A 代码与实验复现

本项目 GitHub 仓库地址：https://github.com/daomuyang/CNPJ_Liesen_Gai。仓库已上传全部代码、预处理脚本、报告源文件(report.tex/report.pdf)、图表(report_figures/)及 README.md；.DS_Store、__pycache__/, LaTeX 编译临时文件等未上传。完整项目结构见仓库中的 README.md。

B 实验环境与复现步骤

实验环境：Ubuntu 22.04, CUDA 12.8.1, Python 3.12.13, PyTorch 2.10.0, GPU NVIDIA A10 (24 GB)。

完整复现流程：

1. 克隆仓库并配置环境：

```
git clone https://github.com/daomuyang/CNPJ_Liesen_Gai.git
cd CNPJ_Liesen_Gai/CNPJ/
python3 -m venv .venv && source .venv/bin/activate
```

```
pip install -r requirements.txt
```

2. 准备数据：将 UK Biobank T1 数据集复制至 `data/raw/` 目录下，每例一个子文件夹，内含 `T1_noisy.nii.gz` 和 `T1_clean.nii.gz`。目录结构为 `data/raw/{caseid}/T1_noisy.nii.gz` 与 `data/raw/{caseid}/T1_clean.nii.gz`。
3. 下载实验中间结果：从百度网盘（链接见下文）下载 `experiments/` 文件夹，解压后放置于 `CNPJ/experiments/`。

百度网盘：<https://pan.baidu.com/s/1mEfSFJ5ys1GsNMqpV41tRQ?pwd=2xx2> 提取码：2xx2

4. 按序运行实验：

```
python preprocess.py          # 预处理（生成 data/preprocessed/）
python run_preliminary.py      # 预实验 Stage A+B+C（约 83 分钟）
python run_full_train.py       # 全量训练 Stage D（约 54 分钟）
python run_baseline.py         # NLM 传统基线（可选，约 30 分钟）
python run_visualization.py    # 后处理可视化（约 3 分钟）
python generate_figures.py     # 生成报告图表
```

5. 编译报告：

```
xelatex report.tex && xelatex report.tex
```

C 模型选择建议

本报告基于“三层递进评估 + 一层全量验证”框架，对五类架构进行了系统筛选。根据不同使用场景，给出以下模型选择建议：

- **精度 — 稳定性综合最优（推荐方案）**：U-Net 32ch。test PSNR 48.14 dB（增益 2.68 dB），跨种子 $2\sigma = 0.19$ dB，7.76M 参数适中。单次训练即可获得稳定可靠结果，适合科研复现与批量部署。
- **纯精度最优（需额外验证种子稳定性）**：SE-UNet 32ch。test PSNR 48.23 dB（增益 2.77 dB），以仅 +1.1% 参数增量换取 +0.09 dB 提升。3 次种子观测中出现 1 例训练失效（ $2\sigma = 1.77$ dB），建议至少运行 5–10 次独立种子训练，选取验证集最优 checkpoint 以避免收敛失败。适合可在充足算力下进行跨种子验证的场景。

- **参数效率最优 (小样本/短训练场景): UNet++ Lite。** 2.00M 参数在 120 例 1500 步下达到 2.62 dB 增益, 单位参数效率为 U-Net 32ch 的 4 倍。嵌套密集跳连提供短梯度路径, 在小数据和短步长下收敛极快。但全量 480 例 5000 步下因容量不足出现泛化坍塌——仅适用于训练数据量不超过 ~ 120 例的有限预算场景, 不适配大数据量全量训练。
- **高容量方案 (不推荐, 性价比极低): U-Net 64ch。** 31.04M 参数 (4 倍于 32ch), test gain 2.72 dB 仅高出 +0.05 dB, 跨种子 $2\sigma = 0.82$ dB。在 128^2 分辨率下, 32 基础通道已触及 U-Net 架构的表示容量上限, 翻倍通道数无法带来实质增益。
- **最低参数量方案 (不推荐, 性能上限低): RED-CNN。** 1.02M 参数, Stage B gain 2.47 dB ($\Delta = 0.16$ dB vs. 最优), 因感受野线性增长限制全局噪声建模能力, 未进入后续筛选。